

Genômica Bacteriana e Filogenia - Roteiro da Atividade Prática

Dia 2 do minicurso Bioinformática Básica e Aplicada à Genômica e Transcriptômica

Discentes responsáveis: Isabel de Farias Ribeiro, Joyce de Souza e Rodrigo Lusa

28/07/2026

Contents

1	Controle de qualidade e pré-processamento das leituras (reads) brutas	2
2	Montagem de genomas bacterianos	3
3	Controle de qualidade de genomas bacterianos	3
4	Anotação de genomas e prospecção de genes de resistência	4
5	Filogenia bacteriana e construção de árvores filogenéticas	7

1 Controle de qualidade e pré-processamento das leituras (reads) brutas

Nesta aula prática, vamos trabalhar com dados de sequenciamento de genoma completo de um isolado da bactéria *Acinetobacter baumannii*. Para isso, realizaremos o download dos dados brutos de sequenciamento de uma amostra disponível no repositório público European Nucleotide Archive (ENA; <https://www.ebi.ac.uk/ena/browser/home>).

Primeiro, no seu ambiente de trabalho no servidor, crie um diretório específico para este módulo do curso. Isso ajudará a manter os arquivos organizados. Em seguida, acesse esse diretório:

```
$ mkdir bacteria
$ cd bacteria
```

O sequenciamento utilizado nesta atividade foi realizado pela metodologia paired-end, na qual cada fragmento de DNA é sequenciado a partir de suas duas extremidades. Por isso, faremos o download de dois arquivos: um contendo as leituras forward (R1) e outro contendo as leituras reverse (R2):

```
#Forward
$ wget ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR682/005/SRR6826835/SRR6826835_1.fastq.gz
```

```
#Reverse
$ wget ftp://ftp.sra.ebi.ac.uk/vol1/fastq/SRR682/005/SRR6826835/SRR6826835_2.fastq.gz
```

Para verificar a estrutura dos arquivos FASTQ diretamente no terminal, podemos utilizar o seguinte comando:

```
$ less SRR6826835_1.fastq.gz
$ less SRR6826835_2.fastq.gz
#para sair do comando less pressione a tecla q
```

Para verificar a qualidade das leituras produzidas pelo sequenciamento, vamos utilizar a ferramenta FastQC (<https://github.com/s-andrews/FastQC>). Antes de executar a análise, vamos criar um diretório específico para armazenar os resultados gerados:

```
$ mkdir FastQC
```

Agora, vamos executar a análise de qualidade nos dois arquivos .fastq.gz, indicando o diretório que acabamos de criar como saída para os resultados (-o):

```
$ fastqc *.fastq.gz -o FastQC
#*todos os arquivos com a extensão .fastq.gz
```

Como resultado, o FastQC gera, para cada arquivo analisado, um relatório no formato .html. Esse relatório pode ser visualizado em qualquer navegador:

```
$ firefox SRR6826835_1_fastqc.html
$ firefox SRR6826835_2_fastqc.html
```

Caso o FastQC indique baixa qualidade nas leituras, é possível realizar uma etapa de limpeza dos dados utilizando ferramentas como o Trimmomatic (<http://www.usadellab.org/cms/index.php?page=trimmomatic>). Essa limpeza tem como objetivo remover resquícios de adaptadores e leituras ou bases de baixa qualidade, que geralmente se encontram nas extremidades das sequências.

2 Montagem de genomas bacterianos

A partir dos dados de sequenciamento precisamos realizar a montagem desse genoma. No caso de genomas bacterianos, as abordagens de montagem de novo são amplamente empregadas. Um desses montadores é o SPAdes (<https://github.com/ablab/spades>), cuja montagem se baseia na construção de grafos de Bruijn para sobreposição das leituras.

Para realizar a montagem do genoma de *A. baumannii* que estamos analisando neste minicurso, vamos rodar a ferramenta SPAdes indicando os arquivos com as leituras forward (-1) e reverse (-2), o diretório de saída (-o) e o número de threads para processamento em paralelo (-t):

```
$ spades.py -1 SRR6826835_1.fastq.gz -2 SRR6826835_2.fastq.gz -o SPAdes -t 20
```

O SPAdes gera como resultado diversos arquivos. Para esse curso, vamos focar principalmente no contigs.fasta. Ele contém todos os contigs que o montador conseguiu identificar. Podemos utilizar o comando less no terminal para visualizar o arquivo e entender seu formato:

```
$ less contigs.fasta
#para sair do comando less pressione a tecla q``
```

3 Controle de qualidade de genomas bacterianos

Neste exercício vamos comparar genomas completos e MAGs usando duas ferramentas amplamente utilizadas:

- QUAST (<https://github.com/ablab/quast>)
- BUSCO (https://busco.ezlab.org/busco_userguide.html)

Entrar no diretório da seção de controle de qualidade:

```
$ cd Controle-de-Qualidade-de-Genomas-Bacterianos/
$ ls
```

A) Quast:

```
$ quast fastas/*.fasta \
-t 32 \
-o results/quast_out
```

Abrir os arquivos gerados:

```
$ cat results/quast_out/report.tsv
$ firefox results/quast_out/icarus.html
```

Observe:

- número de contigs
- tamanho total da montagem

- N50
- fragmentação
- Compare os MAGs com os genomas completos.

Perguntas:

1. Qual montagem apresenta maior fragmentação?
2. Qual possui maior N50?
3. O tamanho total dos genomas é semelhante?

B) BUSCO

Ativar o ambiente conda

```
$ conda activate busco_env
```

Estando dentro da pasta que contém run_busco.sh e rodar o script

```
$ bash run_busco.sh
```

Prática: mover os arquivos gerados para results/

Plotar o gráfico:

```
$ busco --plot busco_json/
```

Abrir os resultados:

```
$ results/busco_json/busco_figure.png
```

4 Anotação de genomas e prospecção de genes de resistência

Após a montagem e a avaliação da qualidade do genoma, o próximo passo é identificar os genes presentes na sequência montada e inferir suas possíveis funções. Esse processo é conhecido como anotação genômica e permite identificar genes codificadores de proteínas, RNAs, elementos estruturais e proteínas hipotéticas.

Nesta atividade utilizaremos o Prokka (<https://github.com/tseemann/prokka>), uma ferramenta amplamente utilizada para anotação de genomas bacterianos. Em seguida, exploraremos os resultados utilizando o Artemis (<https://github.com/sanger-pathogens/Artemis>) e realizaremos a identificação de genes de resistência a antimicrobianos utilizando o RGI (<https://github.com/arpcard/rgi>), baseado no banco de dados CARD (<https://card.mcmaster.ca/home>).

- Acesse a pasta da atividade

Primeiro, entre no diretório onde estão os arquivos que serão utilizados na anotação:

```
$ cd curso_de_inverno/terca/Anotacao
```

- Visualize os arquivos de entrada

Antes de iniciar a anotação, observe os dois arquivos que serão utilizados.

E_coli.fna - genoma da bactéria que será anotado.

E_coli_ref.fna - proteínas de uma cepa de referência, utilizadas para auxiliar a anotação pelo Prokka.

```
$ less E_coli.fna
$ less E_coli_ref.fna
#Para sair da visualização, pressione q
```

- Retorne ao seu diretório

Agora volte para o diretório Desktop, onde será criada a pasta de saída da anotação:

```
$ cd ../../alunos/SEU_NOME
```

- Execute a anotação com o Prokka:

```
$ prokka --outdir Output_Prokka --proteins ../../terca/Anotacao/E_coli_ref.fna \
../../terca/Anotacao/E_coli.fna --prefix E_coli
```

Parâmetros:

—**outdir** (diretório de saída): define a pasta onde todos os arquivos gerados pelo Prokka serão armazenados.

—**proteins** (proteínas de referência): fornece um conjunto de proteínas previamente conhecidas para auxiliar a anotação dos genes, aumentando a precisão na identificação de genes codificadores de proteínas.

—**prefix**: Prefixo dos arquivos de saída.

- Visualizando a anotação no Artemis

O Artemis é um software de visualização que permite explorar o genoma anotado e analisar as características dos genes identificados pelo Prokka.

```
$ art E_coli.gbk
```

- Identificação de proteínas hipotéticas

Na barra superior selecione View > CDS Genes e Products. Observe a proporção de proteínas hipotéticas.

Identificação dos genes de resistência

Depois da anotação estrutural e funcional do genoma, podemos investigar a presença de genes associados à resistência aos antimicrobianos. Nesta atividade utilizaremos o Resistance Gene Identifier (RGI), que compara as proteínas previstas pelo Prokka com o banco de dados CARD (Comprehensive Antibiotic Resistance Database).

Volte ao seu diretório, crie um diretório chamado “Resistencia” e entre dentro desse novo diretório:

```
$ cd ..  
$ mkdir Resistencia  
$ cd Resistencia
```

- Ative o ambiente Conda do RGI

Antes de executar a ferramenta, ative o ambiente onde o RGI está instalado.

```
$ conda activate rgi
```

- Execute o RGI para identificar genes de resistência

O RGI será executado utilizando as proteínas preditas pelo Prokka como entrada.

```
$ rgi main --input_sequence ../Output_Prokka/*.faa --output_file output_rgi \  
--input_type protein --alignment_tool blast
```

Parâmetros:

--input_sequence (sequência de entrada): Define o arquivo de entrada utilizado na análise. Neste caso, são utilizadas as sequências de proteínas preditas pelo Prokka.

--output_file: Nome dos arquivos de saída.

--input_type: Indica o tipo de sequência do arquivo de entrada (Ex: Proteins, Contigs).

--alignment_tool (ferramenta de alinhamento): Define o algoritmo utilizado para comparar as proteínas contra o banco de dados CARD.

- Abrir o notebook de análise

Acesse o notebook https://colab.research.google.com/drive/1YF6iNGS7c_PP9Ao2QPsb_SYNenrwDYSc?usp=sharing, disponibilizado para a visualização dos genes de resistência identificados pelo RGI. O notebook contém os comandos necessários para realizar o processamento dos resultados e gerar uma representação gráfica dos genes identificados.

- Criar uma cópia do notebook

Como o arquivo original deve ser mantido, crie uma cópia para realizar as modificações e executar as análises.

No Google Colab: Arquivo > Salvar uma cópia no Drive

- Executar o notebook

Clique em executar tudo.

5 Filogenia bacteriana e construção de árvores filogenéticas

Para realizar a reconstrução filogenética do genoma que montamos, utilizaremos o gene marcador 16S rRNA. Para isso, adicionaremos ao nosso conjunto de dados as sequências do gene 16S de outros isolados do gênero *Acinetobacter*, além de uma sequência de *Pseudomonas aeruginosa*, que será usada como outgroup para enraizamento da árvore. Um arquivo FASTA contendo todas essas sequências já foi criado e estará disponível para análise.

Antes de fazer o download crie um diretório para armazenar esse arquivo e o resultado das análises filogenéticas:

```
$ mkdir filogenia
$ cd filogenia
```

Agora faça o download do arquivo fasta com as sequências de 16S:

```
$ wget https://raw.githubusercontent.com/ICC-BioGC/2026-Curso_Inverno/
refs/heads/main/materiais/data/16S_rRNA_Acinetobacter.fasta
```

O primeiro passo de uma análise filogenética é realizar o alinhamento múltiplo das sequências. Para isso vamos utilizar a ferramenta MAFFT (<https://mafft.cbrc.jp/alignment/software/>):

```
$ mafft --auto --thread 10 16S_rRNA_Acinetobacter.fasta > 16S_rRNA_Acinetobacter.mafft
```

Podemos visualizar a estrutura desse arquivo de alinhamento:

```
$ less 16S_rRNA_Acinetobacter.mafft
#para sair do comando less pressione a tecla q
```

A partir do alinhamento múltiplo das sequências vamos realizar a reconstrução filogenética pelo método de máxima verossimilhança implementado na ferramenta IQ-Tree (<https://iqtree.github.io/>). Vamos estabelecer o valor de 1000 réplicas de ultrafast-bootstrap, padrão mínimo exigido pela ferramenta:

```
$ iqtree -s 16S_rRNA_Acinetobacter.mafft -nt 20 -bb 1000
```

Assim como outras ferramentas, o IQ-Tree gera diversos arquivos como resultado. A árvore em si é o arquivo com a extensão .treefile, em formato textual com as coordenadas da árvore. Para transformar essas coordenadas em visualização gráfica, precisamos utilizar um interpretador, que pode ser bibliotecas específicas em R ou Python, ou então uma interface gráfica como é o caso do iTOL (<https://itol.embl.de/>), utilizado para exibição, anotação e gerenciamento de árvores filogenéticas.

Vamos acessar o site do iTOL (<https://itol.embl.de/>) e criar um usuário para login em **Register**. Depois de preencher os dados, faça o login e acesse o ícone **My Trees**. Em seguida, acesse os ícones **Tree Upload** e **Select files to upload** e, por fim, localize o arquivo da árvore (.treefile).

Agora podemos visualizar a relação filogenética entre os organismos em análise, e explorar as opções de anotação fornecidas pelo iTOL.